



دانشگاه بیرجند
University of Birjand

دانشکده مهندسی کامپیوتر و فناوری اطلاعات

گزارش پروژه درس پردازش زبان و گفتار

تحلیل احساسات توییت ها با استفاده از مدل های زبانی مبتنی ترنسفورمرها

دانشجو:

الهام نصیری (۴۰۱۱۲۲۶۵۸۲)

استاد:

دکتر پارسا باقرزاده

تیرماه ۱۴۰۵

۱. مرور روش:

برای سنجش ایزوله و سیستماتیک اثر هر متغیر بر عملکرد مدل‌ها، سناریوهای آزمایشی در قالب ۴ شاخه اصلی (Ablation Arms) طراحی شده‌اند. تمامی ۵ مدل در تمام شاخه‌ها تحت پروتکل یکسان ارزیابی می‌شوند:

شاخه ۱ و ۱b: ارزیابی بهینه‌ساز، نرخ یادگیری و پایش دوره‌ها (Hyperparameters & Epoch Sweep)

در این شاخه، اثر متقابل انتخاب بهینه‌ساز و نرخ یادگیری روی نرخ همگرایی مدل‌ها بررسی می‌شود:

- فضای جستجوی هایپرپارامترها: ترکیب دو نرخ یادگیری (2×10^{-5} و 5×10^{-5}) و دو بهینه‌ساز (AdamW و SGD)

• تحلیل دوره‌های آموزش: (Epoch Sweep)

- ترکیب پیش‌فرض ($lr = 2 \times 10^{-5}$ و AdamW) جهت بررسی رفتار طولانی‌مدت مدل و روند افت/رشد عملکرد، آموزش تا ۴ دوره (Epoch) ادامه می‌یابد.

- سایر ترکیب‌ها: برای سایر حالت‌های هایپرپارامتری، آموزش طی ۲ دوره اجرا می‌گردد.

شاخه ۲: تحلیل اثر پاک‌سازی و پیش‌پردازش متن (Preprocessing Ablation)

جهت ارزیابی میزان حساسیت مدل‌های پایه به دستکاری متون ورودی، آزمایش‌ها با ثابت نگه‌داشتن نرخ یادگیری (2×10^{-5})، بهینه‌ساز (AdamW) و طول توالی (۹۶) در دو حالت متن اجرا می‌شوند:

- ورودی خام: (raw) متن بدون هیچ‌گونه دستکاری اولیه به توکنایزر داده می‌شود.
- ورودی پاک‌سازی شده: (cleaned) اعمال چهار مرحله پیش‌پردازش شامل:

۱. حذف پیوندها (URLs)

۲. حذف ارجاعات/منشن‌ها (@)

۳. حذف فضاهای خالی اضافه (Extra Whitespaces)

۴. کوچک‌سازی تمام حروف (lowercase)

شاخه ۳: تحلیل حساسیت طول توالی ورودی (Sequence Length Ablation)

برای سنجش تاثیر میزان ساختار کلامی/فضایی ورودی بر عملکرد دسته‌بندی، طول توالی تغییر داده می‌شود. در این شاخه، حالت متن خام (raw)، نرخ یادگیری (2×10^{-5}) و بهینه‌ساز AdamW ثابت بوده و طول توالی‌های زیر ارزیابی می‌شوند:

- طول توالی ۶۴

- طول توالی ۱۲۸

(توضیح: طول توالی ۹۶ به عنوان حالت پایه در شاخه ۱ ارزیابی شده است)

شاخه ۴: تحلیل استراتژی تنظیم دقیق (Fine-tuning Strategy Ablation)

این شاخه میزان نیاز به به‌روزرسانی کامل پارامترهای کدگذار در برابر انجماد لایه‌ها را تحلیل می‌کند (با تنظیمات ثابت ($lr = 2 \times 10^{-5}$ ، بهینه‌ساز AdamW، طول توالی ۹۶ و متن خام):

- تنظیم دقیق کامل (full): تمام پارامترها و لایه‌های شبکه در فرآیند آموزش و پس‌انتشار (Backpropagation) به‌روزرسانی می‌شوند.
- کدگذار منجمد (frozen_encoder): وزن‌های بخش کدگذار (Encoder) منجمد شده و فرآیند یادگیری تنها به لایه‌های بالایی دسته‌بندی‌کننده (شامل pooler، classifier، pre_classifier محدود می‌گردد).

پروتکل پایش آنلاین، انتخاب مدل برتر و ثبت خطاها

- ارزیابی در لحظه (Online Evaluation): در تمامی شاخه‌ها، بلافاصله پس از پایان هر دوره آموزش (Epoch)، ارزیابی مدل به‌صورت هم‌زمان بر روی هر دو مجموعه اعتبارسنجی (Dev) و آزمون (Test) انجام می‌پذیرد.
- معیار انتخاب پیکربندی برنده: معیار کلیدی جهت ردیابی عملکرد، امتیاز Weighted F1 روی مجموعه Dev است.
- پروتکل به‌روزرسانی بهترین حالت: اگر امتیاز Dev F1 در یک دوره مشخص از بالاترین امتیاز ثبت شده تا آن لحظه پیشی بگیرد:

۱. آن پیکربندی و کلیه متریک‌های ارزیابی مرتبط به‌عنوان بهترین حالت مدل به‌روزرسانی و ذخیره می‌شوند.

۲. فهرست کامل نمونه‌های اشتباه پیش‌بینی شده روی مجموعه آزمون (Misclassified Test Samples) جهت تحلیل خطای یکپارچه استخراج و نگهداری می‌گردد.

۲. تنظیمات آزمایش ها

• مدل ها:

انتخاب مدل ها با هدف پوشش حداکثری انواع انکودرها در پردازش زبان طبیعی صورت گرفته شد (در واقع به جز مدل برت بقیه صورت رندوم انتخاب شدند):

- bert-base-cased: به عنوان مدل پایه دوطرفه انتخاب شد [1]. حفظ ساختار حروف بزرگ و کوچک (Cased) امکان درک لحن های تاکید شده در شبکه اجتماعی توییتر را فراهم می سازد.
- albert-base-v2: این مدل با استفاده از تکنیک تسهیم پارامترها در لایه ها و تجزیه فاکتورهای ماتریس تعبیه سازی، حجم محاسباتی را به حداقل می رساند [2].
- cardiffnlp/twitter-roberta-base-sentiment-latest: نسخه ای بهبود یافته از معماری RoBERTa که با حجم عظیمی از داده های متنی توییتر سازگار و بر روی وظیفه تحلیل احساسات تخصصی پیش آموزش دیده است [3].
- vinai/bertweet-base: مدلی پیش آموزش دیده بر روی داده های متنی خرد که پیش پزشگر داخلی آن به طور خودکار ایموجی ها، نام های کاربری و پیوندها را نرمال سازی می کند [4].
- distilbert-base-uncased-finetuned-sst-2-english: نسخه ای تقطیر شده که با حفظ ۹۷ درصد توانایی BERT پایه، حجم پارامترها را تا ۴۰ درصد کاهش داده است [5].

• تنظیمات مورد استفاده و ابرپارامترها و روش ها

پارامترهای بهینه سازی سیستم به شرح زیر است:

- انتخاب مدل زبانی (Arm اصلی، روی همه ی Arm ها اعمال می شود)
- خواسته مسئله: استفاده از چند مدل زبانی مختلف مانند BERT ، RoBERTa ، DistilBERT، ALBERT یا مدل های مشابه.
- انتظار: معماری های مختلف (اندازه، هدف pretraining، دامنه ی داده ی pretraining) باید تفاوت معناداری در Dev/Test F1 ایجاد کنند؛ مثلاً مدل هایی که روی متن شبکه های اجتماعی pretrain شده اند مثل BERTweet یا مدل RoBERTa توییتر روی داده ی توییت انتظار می رود عملکرد بهتری نسبت به مدل های عمومی داشته باشند.

- رفتار کد: لیست MODELS_LIST شامل 5 مدل است (۴ مدل الزامی + 1 مدل اضافه)
- حلقه‌ی بیرونی main() برای هر model_path تمام Arm های زیر را به‌طور کامل و مستقل تکرار می‌کند، و در پایان بهترین کانفیگ هر مدل بر اساس Dev F1 در 4_final_models_benchmark.csv ثبت می‌شود.

○ نرخ یادگیری × بهینه‌ساز (Arm 1)

طول ورودی و epoch در این Arm ثابت نگه داشته می‌شوند تا فقط اثر lr/optimizer دیده شود.

- خواسته مسئله: بررسی تأثیر ابرپارامترها، به‌طور مشخص نرخ یادگیری (Learning Rate) و بهینه‌ساز (Optimizer).
- انتظار: AdamW معمولاً برای fine-tuning ترنسفورمرها پایدارتر و سریع‌تر از SGD همگرا می‌شود؛ نرخ یادگیری بالاتر (5e-5) می‌تواند همگرایی سریع‌تر اما ریسک بی‌ثباتی /overfitting بیشتری داشته باشد. انتظار می‌رود بهترین ترکیب بین این چهار حالت (۲ نرخ × ۲ بهینه‌ساز) بر اساس Dev F1 انتخاب شود.

- رفتار کد: حلقه‌ی تودرتوی for lr in [2e-5, 5e-5] × for opt_name in [AdamW, SGD] برای هر مدل، ۴ ترکیب مستقل را روی ۲ epoch آموزش می‌دهد (پیش‌پردازش: raw، طول=۹۶ ثابت) پس از هر epoch، Dev F1 و متریک‌های Test محاسبه و در hyperparameter_logs ثبت می‌شوند؛ بهترین Dev F1 در سراسر تمام Arm ها مقایسه می‌شود.

○ تعداد دوره‌های آموزش Epoch (Arm 1b)

این Arm با warm-start از Arm 1 ادامه می‌یابد تا از آموزش تکراری epoch=1,2 جلوگیری شود.

- خواسته مسئله: تعداد دوره‌های آموزش (Epochs) هم باید مانند نرخ یادگیری و بهینه‌ساز به‌عنوان یک ابرپارامتر مستقل بررسی شود، نه که ضمنی از میان‌راه انتخاب شود.
- انتظار: افزایش epoch از ۲ به ۴ می‌تواند F1 روی Dev را بهبود دهد (یادگیری بیشتر) یا کاهش دهد

(overfitting روی train_set با ۱۰,۰۰۰ نمونه) هدف، پیدا کردن نقطه‌ای است که Dev F1 دیگر بهبود پیدا نمی‌کند یا شروع به افت می‌کند.

رفتار کد: برای ترکیب $lr=default(2e-5)$ و AdamW، مدل و optimizer از Arm 1 نگه داشته می‌شوند (warm_start_model)، مقادیر $epoch=1,2$ عیناً از لاگ Arm 1 کپی می‌شوند (arm1_default_epoch_logs) یعنی بدون آموزش مجدد.

بعد همان مدل برای epoch ۲ دیگر (۳ و ۴) روی همان train_loader ادامه می‌یابد و $epoch=4$ معادل epoch ۴ کامل و پیوسته‌ی آموزش است، دقیقاً هم‌ارز نسخه‌ی از صفر تا $epoch=4$

○ روش پیش‌پردازش متن (Arm 2)

- خواسته مسئله: بررسی روش‌های مختلف پیش‌پردازش متن.
- انتظار: متن خام توییت شامل نویز زیاد (لینک، mention، حروف بزرگ/کوچک نامنظم) است. حذف URL ها و @mention ها و یکدست‌سازی حروف (پیش‌پردازش cleaned) می‌تواند نویز را کم کند، اما ممکن است اطلاعات مفیدی را هم حذف کند؛ نتیجه از پیش مشخص نیست و باید تجربی سنجیده شود.
- رفتار کد: تابع preprocess_text دو حالت raw (بدون تغییر) و cleaned (حذف URL با regex، حذف @mention، یکدست‌سازی فاصله‌ها، کوچک‌سازی حروف) دارد. برای هر حالت، train/dev/test مجزا پیش‌پردازش و توکنایز می‌شوند و روی epoch ۲ با lr و optimizer پیش‌فرض آموزش داده می‌شوند.

○ طول توالی ورودی (Max Sequence Length (Arm 3)

- خواسته‌ی مسئله: بررسی تأثیر طول ورودی (Maximum Sequence Length)
- انتظار: توییت‌ها معمولاً کوتاه هستند، پس طول کوتاه‌تر (۶۴) ممکن است دقت مشابهی با طول پیش‌فرض (۹۶) داشته باشد اما سریع‌تر اجرا شود؛ طول بلندتر (۱۲۸) در صورتی که توییت‌ها به‌ندرت truncate می‌شوند، سودی نداشته و فقط هزینه‌ی محاسباتی اضافه می‌کند.
- رفتار کد: برای $current_len$ in $[64, 128]$ علاوه بر ۹۶ پیش‌فرض که در Arm 1 پوشش داده شده دیتاست‌ها با آن max_length مجدد توکنایز می‌شوند و روی epoch ۲ با تنظیمات پیش‌فرض دیگر (raw, $lr=2e-5$, AdamW) آموزش داده می‌شوند.

○ روش Fine-Tuning (Arm 4)

- خواسته‌ی مسئله : بررسی تأثیر روش‌های مختلف تنظیم مدل (Fine-Tuning)
- انتظار: در full fine-tuning همه‌ی لایه‌ها به‌روزرسانی می‌شوند و معمولاً بالاترین دقت را می‌دهد اما هزینه‌ی محاسباتی/حافظه بیشتری دارد. در (linear probing) frozen-encoder فقط سر طبقه‌بندی آموزش می‌بیند؛ سریع‌تر و کم‌هزینه‌تر است اما معمولاً F1 پایین‌تری نسبت به full fine-tuning دارد.
- رفتار کد: تابع `apply_finetune_strategy` برای حالت `full`، `requires_grad` همه‌ی پارامترها را `True` می‌کند؛ برای `frozen_encoder`، فقط پارامترهایی که در نامشان `classifier`، `pooler` یا `pre_classifier` باشد `trainable` می‌مانند `optimizer`، فقط با پارامترهای `trainable` ساخته می‌شود تا در حالت `frozen` صرفه‌جویی محاسباتی واقعی رخ دهد.

۳. جدول خلاصه‌ی خروجی‌ها

فایل خروجی	Arm مرتبط	محتوا
1_hyperparameters_report.csv	Arm 1	epoch × lr، هر optimizer
1b_epoch_sweep_report.csv	Arm 1b	epoch=1..4 و ۲ کپی‌شده، ۴ و ۳ واقعی
2_preprocessing_report.csv	Arm 2	raw برابر cleaned
3_sequence_length_report.csv	Arm 3	طول ۶۴ و ۱۲۸
4b_finetune_strategy_report.csv	Arm 4	full در برابر frozen_encoder
4_final_models_benchmark.csv	خلاصه‌ی نهایی	بهترین کانفیگ هر مدل + متادیتا، روی Test
5_unified_error_analysis.csv	تحلیل خطا	نمونه‌های اشتباه بهترین کانفیگ هر مدل
6_fixed_baseline_comparison.csv	مقایسه‌ی منصفانه	همه‌ی ۷ مدل روی یک کانفیگ ثابت مشترک

۳. نتایج تجربی

Model	Learning_Rate	Optimizer	Epoch	Dev_F1_Score	Test_Accuracy	Test_F1_Score
bert-base-cased	2.00E-05	AdamW	1	0.6981	0.7061	0.7058
bert-base-cased	2.00E-05	AdamW	2	0.6939	0.7015	0.7017
bert-base-cased	2.00E-05	SGD	1	0.3779	0.4624	0.3725
bert-base-cased	2.00E-05	SGD	2	0.4608	0.5024	0.4578
bert-base-cased	5.00E-05	AdamW	1	0.663	0.6761	0.6705
bert-base-cased	5.00E-05	AdamW	2	0.6904	0.6872	0.6876
bert-base-cased	5.00E-05	SGD	1	0.4112	0.4965	0.4184
bert-base-cased	5.00E-05	SGD	2	0.5002	0.5562	0.5045
twitter-roberta-base-sentiment-latest	2.00E-05	AdamW	1	0.7463	0.7476	0.7449
twitter-roberta-base-sentiment-latest	2.00E-05	AdamW	2	0.7535	0.7558	0.7554
twitter-roberta-base-sentiment-latest	2.00E-05	SGD	1	0.7697	0.7814	0.7813
twitter-roberta-base-sentiment-latest	2.00E-05	SGD	2	0.7763	0.7854	0.7856
twitter-roberta-base-sentiment-latest	5.00E-05	AdamW	1	0.7106	0.7151	0.7084
twitter-roberta-base-sentiment-latest	5.00E-05	AdamW	2	0.7277	0.7235	0.7168
twitter-roberta-base-sentiment-latest	5.00E-05	SGD	1	0.7695	0.7769	0.7758

twitter-roberta-base-sentiment-latest	5.00E-05	SGD	2	0.7726	0.7789	0.779
distilbert-base-uncased-finetuned-sst-2-english	2.00E-05	AdamW	1	0.6713	0.6721	0.6656
distilbert-base-uncased-finetuned-sst-2-english	2.00E-05	AdamW	2	0.6924	0.6957	0.6961
distilbert-base-uncased-finetuned-sst-2-english	2.00E-05	SGD	1	0.503	0.5532	0.5022
distilbert-base-uncased-finetuned-sst-2-english	2.00E-05	SGD	2	0.571	0.578	0.5538
distilbert-base-uncased-finetuned-sst-2-english	5.00E-05	AdamW	1	0.6997	0.6931	0.6926
distilbert-base-uncased-finetuned-sst-2-english	5.00E-05	AdamW	2	0.6943	0.6949	0.6943
distilbert-base-uncased-finetuned-sst-2-english	5.00E-05	SGD	1	0.5979	0.6048	0.5931
distilbert-base-uncased-finetuned-sst-2-english	5.00E-05	SGD	2	0.6257	0.6303	0.6277
albert-base-v2	2.00E-05	AdamW	1	0.6845	0.6818	0.6804
albert-base-v2	2.00E-05	AdamW	2	0.6937	0.6941	0.6933
albert-base-v2	2.00E-05	SGD	1	0.2809	0.4467	0.2758
albert-base-v2	2.00E-05	SGD	2	0.2809	0.4467	0.2758
albert-base-v2	5.00E-05	AdamW	1	0.6402	0.6499	0.6433
albert-base-v2	5.00E-05	AdamW	2	0.6791	0.6923	0.6922
albert-base-v2	5.00E-05	SGD	1	0.6544	0.6646	0.6504
albert-base-v2	5.00E-05	SGD	2	0.6941	0.6923	0.6908
bertweet-base	2.00E-05	AdamW	1	0.7265	0.7318	0.7321
bertweet-base	2.00E-05	AdamW	2	0.7128	0.7171	0.7198
bertweet-base	2.00E-05	SGD	1	0.2809	0.4467	0.2758

bertweet-base	2.00E-05	SGD	2	0.2809	0.4467	0.2758
bertweet-base	5.00E-05	AdamW	1	0.7144	0.7239	0.724
bertweet-base	5.00E-05	AdamW	2	0.6134	0.6427	0.6212
bertweet-base	5.00E-05	SGD	1	0.2809	0.4465	0.2766
bertweet-base	5.00E-05	SGD	2	0.3158	0.4614	0.319

جدول شماره 1: hyperparameter

Model	Total_Epochs	Dev_F1_Score	Test_Accuracy	Test_F1_Score
bert-base-cased	2	0.6939	0.7015	0.7017
bert-base-cased	4	0.6835	0.6948	0.6933
twitter-roberta-base-sentiment-latest	2	0.7535	0.7558	0.7554
twitter-roberta-base-sentiment-latest	4	0.7422	0.742	0.7422
distilbert-base-uncased-finetuned-sst-2-english	2	0.6924	0.6957	0.6961
distilbert-base-uncased-finetuned-sst-2-english	4	0.6831	0.6852	0.6841
albert-base-v2	2	0.6937	0.6941	0.6933
albert-base-v2	4	0.6572	0.6727	0.6641
bertweet-base	2	0.7128	0.7171	0.7198
bertweet-base	4	0.7213	0.722	0.7213

جدول شماره 1b: epoch sweep

Model	Preprocessing_Strategy	Epoch	Dev_F1_Score	Test_Accuracy	Test_F1_Score
bert-base-cased	raw	1	0.7063	0.7026	0.7014
bert-base-cased	raw	2	0.6855	0.6928	0.6922
bert-base-cased	cleaned	1	0.7046	0.7011	0.7021
bert-base-cased	cleaned	2	0.6938	0.6904	0.6873
twitter-roberta-base-sentiment-latest	raw	1	0.7455	0.7465	0.7435
twitter-roberta-base-sentiment-latest	raw	2	0.7589	0.7549	0.7546
twitter-roberta-base-sentiment-latest	cleaned	1	0.7389	0.7413	0.7378
twitter-roberta-base-sentiment-latest	cleaned	2	0.7359	0.7444	0.741

distilbert-base-uncased-finetuned-sst-2-english	raw	1	0.6744	0.6726	0.6659
distilbert-base-uncased-finetuned-sst-2-english	raw	2	0.6963	0.6966	0.6969
distilbert-base-uncased-finetuned-sst-2-english	cleaned	1	0.673	0.6789	0.674
distilbert-base-uncased-finetuned-sst-2-english	cleaned	2	0.6906	0.695	0.6955
albert-base-v2	raw	1	0.6893	0.6902	0.685
albert-base-v2	raw	2	0.6912	0.6921	0.6918
albert-base-v2	cleaned	1	0.7087	0.6935	0.6935
albert-base-v2	cleaned	2	0.6874	0.6902	0.6903
bertweet-base	raw	1	0.7274	0.7327	0.733
bertweet-base	raw	2	0.7161	0.7251	0.7275
bertweet-base	cleaned	1	0.7244	0.7272	0.7275
bertweet-base	cleaned	2	0.7101	0.7273	0.7281

جدول شماره 2: preprocessing

Model	Max_Sequence_Length	Epoch	Dev_F1_Score	Test_Accuracy	Test_F1_Score
bert-base-cased	64	1	0.6888	0.6963	0.6939
bert-base-cased	64	2	0.7044	0.6993	0.6993
bert-base-cased	128	1	0.7028	0.7083	0.7083
bert-base-cased	128	2	0.7012	0.7039	0.7036
twitter-roberta-base-sentiment-latest	64	1	0.7411	0.7378	0.7324
twitter-roberta-base-sentiment-latest	64	2	0.747	0.7508	0.7481
twitter-roberta-base-sentiment-latest	128	1	0.7419	0.7421	0.7381
twitter-roberta-base-sentiment-latest	128	2	0.7379	0.7479	0.7434
distilbert-base-uncased-finetuned-sst-2-english	64	1	0.6772	0.6782	0.6731
distilbert-base-uncased-finetuned-sst-2-english	64	2	0.7001	0.6999	0.6998
distilbert-base-uncased-finetuned-sst-2-english	128	1	0.6621	0.6767	0.67
distilbert-base-uncased-finetuned-sst-2-english	128	2	0.7015	0.6962	0.6962

albert-base-v2	64	1	0.6977	0.6884	0.6872
albert-base-v2	64	2	0.7041	0.6999	0.7
albert-base-v2	128	1	0.7006	0.6923	0.6896
albert-base-v2	128	2	0.697	0.6993	0.6991
bertweet-base	64	1	0.7352	0.7316	0.7315
bertweet-base	64	2	0.729	0.7323	0.7329
bertweet-base	128	1	0.73	0.732	0.7314
bertweet-base	128	2	0.7258	0.7378	0.7388

جدول شماره 3: sequence length

Model	FineTune_Strategy	Epoch	Dev_F1_Score	Test_Accuracy	Test_F1_Score
bert-base-cased	full	1	0.7008	0.7029	0.7018
bert-base-cased	full	2	0.6859	0.6973	0.697
bert-base-cased	frozen_encoder	1	0.4434	0.5281	0.4582
bert-base-cased	frozen_encoder	2	0.517	0.562	0.5133
twitter-roberta-base-sentiment-latest	full	1	0.7483	0.7461	0.743
twitter-roberta-base-sentiment-latest	full	2	0.7578	0.7569	0.7563
twitter-roberta-base-sentiment-latest	frozen_encoder	1	0.7721	0.7823	0.782
twitter-roberta-base-sentiment-latest	frozen_encoder	2	0.772	0.7835	0.7831
distilbert-base-uncased-finetuned-sst-2-english	full	1	0.6705	0.6723	0.666
distilbert-base-uncased-finetuned-sst-2-english	full	2	0.6917	0.6968	0.6972
distilbert-base-uncased-finetuned-sst-2-english	frozen_encoder	1	0.6115	0.6171	0.6033
distilbert-base-uncased-finetuned-sst-2-english	frozen_encoder	2	0.6373	0.6441	0.6402
albert-base-v2	full	1	0.6969	0.6935	0.6909
albert-base-v2	full	2	0.695	0.6917	0.6916
albert-base-v2	frozen_encoder	1	0.5025	0.5561	0.5027
albert-base-v2	frozen_encoder	2	0.5597	0.5932	0.5677
bertweet-base	full	1	0.7349	0.7309	0.7314
bertweet-base	full	2	0.7083	0.7155	0.7184
bertweet-base	frozen_encoder	1	0.4929	0.5503	0.5026
bertweet-base	frozen_encoder	2	0.3596	0.4905	0.3746

جدول شماره 4b: finetune strategy

Model	Accuracy	Precision	Recall	F1_Score	Arm	Learning_Rate	Optimizer	Preprocessing	Max_Sequence_Length	Epochs_Trained	Fine Tune_Strategy
bert-base-cased	0.7026	0.7036	0.7026	0.7014	2_preprocessing	2.00E-05	AdamW	raw	96	1	full
twitter-roberta-base-sentiment-latest	0.7854	0.7859	0.7854	0.7856	1_lr_optimizer	2.00E-05	SGD	raw	96	2	full
distilbert-base-uncased-finetuned-sst-2-english	0.6962	0.6966	0.6962	0.6962	3_sequence_length	2.00E-05	AdamW	raw	128	2	full
albert-base-v2	0.6935	0.6956	0.6935	0.6935	2_preprocessing	2.00E-05	AdamW	cleaned	96	1	full
bertweet-base	0.7316	0.7325	0.7316	0.7315	3_sequence_length	2.00E-05	AdamW	raw	64	1	full

جدول 4: final model benchmark

Model	Test_Accuracy	Test_F1_Score
bert-base-cased	0.7015	0.7017
twitter-roberta-base-sentiment-latest	0.7558	0.7554
distilbert-base-uncased-finetuned-sst-2-english	0.6957	0.6961
albert-base-v2	0.6941	0.6933
bertweet-base	0.7171	0.7198

جدول شماره 6: fixed baseline

۴. تحلیل نتایج

۱. بهینه‌ساز و نرخ یادگیری

- برنده اصلی: بهینه‌ساز SGD با نرخ یادگیری 2×10^{-5} روی مدل twitter-roberta بهترین عملکرد را ثبت کرد.

- ثبات کلی: بهینه‌ساز AdamW با نرخ 2×10^{-5} برای سایر مدل‌های عمومی BERT، ALBERT و DistilBERT پایدارترین نتیجه را داد، در حالی که SGD روی آن‌ها دچار افت شدیدی شد.

۲. تعداد دوره‌های آموزش (Epochs)

- بیش‌برازش (Overfitting): افزایش دوره‌ها از ۲ به ۴ در ۴ مدل از ۵ مدل باعث افت F1 شد.

- استثنا: تنها مدل bertweet-base با افزایش دوره‌ها بهبود جزئی نشان داد.

۳. اثر پیش‌پردازش متن

- مدل‌های متون اجتماعی: پاک‌سازی متن (حذف URL و منشن) عملکرد twitter-roberta را کاهش داد و متن خام (Raw) بهتر بود.

- مدل‌های عمومی: پاک‌سازی متن تنها روی albert-base-v2 اثر مثبت داشت.

۴. استراتژی Fine-tuning

- برتری Full Fine-Tuning: انجماد کدگذار (frozen_encoder) در اکثر مدل‌ها افت شدید F1 را به همراه داشت.

- استثنا: مدل twitter-roberta حتی در حالت Frozen Encoder هم بازنمایی فوق‌العاده بالایی ارائه داد.

۵. مقایسه در شرایط ثابت (Fixed Baseline)

- در تنظیمات کاملاً یکسان، رتبه‌بندی مدل‌ها از نظر Test F1 به ترتیب زیر شد:

1. twitter-roberta (0.7554)

2. bertweet (0.7198)

3. bert-base (0.7017)

4. distilbert (0.6961)

5. albert (0.6933)

۶. بنچمارک نهایی

- مدل قهرمان: مدل twitter-roberta با پیکربندی SGD و متن خام به بالاترین F1 نهایی (0.7856) دست یافت.

- سایر مدل‌های برتر: به ترتیب bertweet (0.7315)، bert-base (0.7014)، distilbert (0.6962) و albert (0.6935) قرار گرفتند.

۵- تحلیل خطاها

بررسی نمونه‌های خطای ثبت‌شده در مدل‌های برتر، الگوهای رفتاری زیر را در مواجهه با چالش‌ها نشان می‌دهد:

- میزان خطا: twitter-roberta با ۱,۵۵۵ خطا، کم‌ترین و albert با ۲,۲۲۱ خطا، بیش‌ترین اشتباه را داشتند.

- چالش اصلی: بیشترین خطای مدل‌ها در تشخیص کلاس خنثی/میانی (کلاس ۱) رخ داد.

- سردرگمی قطبی: اشتباه مستقیم بین دو قطب مخالف (کلاس ۰ و ۲) بسیار ناچیز بود.

(جدول کامل به صورت فایل اکسل در فایل موجود است)

۶- جمع بندی

۱. برتری مطلق مدل‌های تخصصی حوزه (Domain Specialization)

- برنده اصلی: مدل twitter-roberta-base-sentiment-latest با دستیابی به F1 نهایی 0.7856 و کمترین میزان خطا (۱,۵۵۵ خطا روی ۸,۰۰۰ داده تست) به عنوان برترین مدل شناساگر عمل کرد.

- اثر پیش‌آموزش: مدل‌های پیش‌آموزش‌دیده روی داده‌های شبکه‌های اجتماعی (twitter-roberta و roberta bertweet-base) عملکردی به مراتب برتر از مدل‌های زبان عمومی (bert-base-cased، distilbert و albert-base-v2) ثبت کردند (اختلاف F1 بین ۳٪ تا ۹٪).

۲. هایپرپارامترها و پیکربندی بهینه

- بهینه‌ساز: بهینه‌ساز AdamW با نرخ یادگیری 2×10^{-5} عمومی‌ترین و پایدارترین پیکربندی بود. بهینه‌ساز SGD روی مدل‌های عمومی باعث عدم همگرایی یا افت شدید عملکرد شد، اما به عنوان یک استثنا روی twitter-roberta بالاترین F1 کل را ارائه داد.

- تعداد دوره‌ها: (Epochs) اکثر مدل‌ها در دوره ۱ یا ۲ به نقطه اوج عملکرد رسیدند؛ ادامه فرآیند آموزش تا ۴ دوره در اکثر مدل‌ها منجر به بیش‌برازش (Overfitting) و کاهش امتیاز F1 شد.

۳. پیش‌پردازش و استراتژی Fine-tuning

- ارزش متون خام: (Raw Text) پاک‌سازی ساختاری متن (حذف URL ها، منشن‌ها و کوچک‌سازی حروف نه تنها عملکرد مدل‌های تخصصی تویتر را بهبود نداد، بلکه باعث افت F1 در twitter-roberta شد.

- ضرورت: Full Fine-tuning به‌روزرسانی کامل تمامی پارامترها (full) برای اکثر مدل‌ها الزامی است؛ انجماد لایه‌های کدگذار (frozen_encoder) منجر به افت شدید F1 تا حدود ۲۰٪ کاهش در اکثر ساختارها گردید.

۴. الگوهای کلیدی در تحلیل خطاها

- چالش اصلی (کلاس ۱): اصلی‌ترین نقطهٔ ضعف تمامی مدل‌ها مربوط به تشخیص کلاس خنثی/میانی (کلاس ۱) بود؛ به‌طوری که بیش از ۴۳٪ از کل ۱۰,۰۷۸ خطای ثبت‌شده مربوط به عدم تمایز کلاس ۱ از دو کلاس دیگر بوده است.
- عدم سردرگمی قطبی: میزان خطای مستقیم بین دو قطب مخالف (پیش‌بینی کلاس ۰ به جای ۲ یا بالعکس) بسیار ناچیز بود، که نشان‌دهنده درک صحیح مدل‌ها از جهت‌گیری‌های صریح متن است.

مراجع

- [1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," *arXiv preprint arXiv:1810.04805*, 2018. [Online]. Available: <https://arxiv.org/abs/1810.04805>
- [2] Goodman, K. Gimpel, P. Sharma, and R. Soricut, "ALBERT: A Lite BERT for Self-Supervised Learning of Language Representations," in *International Conference on Learning Representations (ICLR)*, 2019. [Online]. Available: <https://arxiv.org/abs/1909.11942>. [Online]. Available: <https://arxiv.org/abs/1909.11942>
- [3] F. Barbieri, J. C. Anke, and L. Espinosa-Anke, "TweetEval: Unified Benchmark and Comparative Evaluation for Tweet Classification," in *Findings of the Association for Computational Linguistics: EMNLP*, 2020, pp. 1644–1650. [Online]. Available: <https://arxiv.org/abs/2009.00000>

<https://arxiv.org/abs/2010.12421>.

[Online].

Available:

<https://arxiv.org/abs/2010.12421>

D. Q. Nguyen, T. Vu, and A. T. Nguyen, "BERTweet: A pre-trained language model for English Tweets," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, 2020, pp. 9–14. [Online].

Available: <https://arxiv.org/abs/2005.10200>.

[Online].

Available:

<https://arxiv.org/abs/2005.10200>

V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," *arXiv preprint arXiv:1910.01108*, 2019. [Online].

.Available: <https://arxiv.org/abs/1910.01108>